

Relatório de Resultados Preliminares — Épico 1

Fine-tuning RTMPose-X no Dataset 3DSP Data: 04 de junho de 2026 | **Hardware:** NVIDIA GeForce RTX 4090 (24 GB)

1. Resumo Executivo

O Épico 1 foi concluído com sucesso. A infraestrutura de fine-tuning foi validada end-to-end na madrugada de 03–04/06, com os Cenários A (from scratch) e C (transfer learning) treinados e avaliados no val split do 3DSP.

Principal resultado: o Transfer Learning (Cenário C) supera o zero-shot RTMPose-X em **+16,6 pp de PCK@0.2** e reduz o MPJPE-2D de 4,81 px para **3,63 px** no melhor checkpoint — demonstrando que o fine-tuning em dados de futebol é fortemente benéfico.

2. Setup Experimental

Item	Valor
Modelo	RTMPose-X (CSPNeXt-X + RTMCCHead SimCC)
Input	288×384 px (letterbox de 100×100)
Dataset	3DSP — 160 clips treino / 40 clips val (3200 / 800 frames)
Keypoints	H3WB-17 (IDs 0,7,8,9 derivados, excluídos da loss)
Batch size	16
Optimizer	AdamW
GPU	NVIDIA RTX 4090 24 GB
Framework	MMPose 1.3.2 + MMEEngine 0.10.7

3. Modelos Avaliados

3.1 Baselines Zero-Shot (sem fine-tuning)

Estes modelos foram treinados em COCO e aplicados diretamente no 3DSP, sem qualquer adaptação.

Modelo	PDJ@0.5	PCK@0.2	OKS	MPJPE-2D
OpenPose	56,1%	22,1%	48,5%	25,58 px
HRNet-W48	88,9%	40,5%	76,2%	6,04 px
RTMPose-X (zero-shot)	93,6%	41,8%	81,8%	4,81 px

RTMPose-X zero-shot é o **baseline principal** para medir o ganho do fine-tuning.

3.2 Cenário A — From Scratch, sem Augmentation

Pesos inicializados aleatoriamente. Treino de 50 épocas com LR uniforme 1×10^{-3} .

Split	PDJ@0.5	PCK@0.2	OKS	MPJPE-2D
Treino	99,6%	83,9%	96,4%	1,54 px
Val	90,7%	47,0%	80,1%	5,34 px

Diagnóstico: overfitting moderado-alto (gap treino → val de **36,9 pp em PCK**). Com apenas 3.200 imagens, o modelo memoriza o treino mas generaliza parcialmente. Ainda assim, supera o zero-shot em PCK@0.2 (+5,2 pp), confirmando que o fine-tuning mesmo do zero agrega valor.

3.3 Cenário C — Transfer Learning, sem Augmentation

Pesos inicializados com checkpoint COCO. Progressive unfreezing em 3 fases.

Progressão por fase (val split)

Fase	Épocas	frozen_stages	LR Head	LR Backbone	PDJ@0.5	PCK@0.2	OKS	MPJPE-2D
Zero-shot (referência)	—	—	—	—	93,6%	41,8%	81,8%	4,81 px
Fase 1 (head only)	10	4	1×10^{-3}	0	91,8%	53,2%	82,8%	4,76 px
Fase 2 (stages 2–3 + neck)	75	2	1×10^{-4}	1×10^{-5}	95,2%	61,5%	87,3%	3,63 px
Fase 3 (stage 1–3)	60	1	1×10^{-4}	1×10^{-6}	93,4%	58,4%	85,1%	4,15 px

Fase	Épocas	frozen_stages	LR Head	LR Backbone	PDJ@0.5	PCK@0.2	OKS	MPJPE-2D
+ neck)								

Melhor checkpoint: Fase 2 (epoch 75) — PCK@0.2 = **61,5%**, MPJPE = **3,63 px**

Split	PDJ@0.5	PCK@0.2	OKS	MPJPE-2D
Treino	98,6%	76,6%	94,2%	2,00 px
Val	93,4%	58,4%	85,1%	4,15 px

Diagnóstico: overfitting menor que o Cenário A (gap de **18,2 pp** vs **36,9 pp**). O ponto de partida COCO fornece representações robustas que resistem melhor ao dataset pequeno.

4. Tabela Comparativa Global

Modelo	PDJ@0.5 ↑	PCK@0.2 ↑	OKS ↑	MPJPE-2D ↓
OpenPose (zero-shot)	56,1%	22,1%	48,5%	25,58 px
HRNet-W48 (zero-shot)	88,9%	40,5%	76,2%	6,04 px
RTMPose-X (zero-shot)	93,6%	41,8%	81,8%	4,81 px
Cenário A (from scratch, val)	90,7%	47,0%	80,1%	5,34 px
Cenário C (TL fase 2, val)	95,2%	61,5%	87,3%	3,63 px

5. Análise por Grupo Anatômico (PCK@0.2, val)

Grupo	Zero-shot RTMPose	Cenário A	Cenário C (melhor)	Δ C vs Zero-shot
Head	50,4%	75,0%	81,4%	+31,0 pp
Shoulder	30,4%	61,8%	73,5%	+43,1 pp
Elbow	50,8%	32,7%	50,6%	+0 pp
Wrist	43,5%	22,9%	39,8%	-3,7 pp
Hip	22,8%	51,0%	63,6%	+40,8 pp

Grupo	Zero-shot RTMPose	Cenário A	Cenário C (melhor)	Δ C vs Zero-shot
Knee	58,3%	37,7%	56,6%	-1,7 pp
Ankle	59,4%	36,1%	60,1%	+0,7 pp

Observações: - O maior ganho do TL está em **head, shoulder e hip** — joints com características visuais de futebol distintas do domínio COCO - **Wrist e elbow** mantêm performance similar ao zero-shot — são joints difíceis independente do método (alta variabilidade de pose durante o chute) - O Cenário A piora elbow/wrist/knee em relação ao zero-shot — sinal de underfitting nesses joints com 3.200 amostras

6. Análise de Overfitting (os 3 números)

Metodologia definida em reunião com professor: comparar (1) performance no treino, (2) performance no val, (3) baseline zero-shot.

Cenário A

```
Treino PCK@0.2 = 83,9%
Val PCK@0.2 = 47,0% ← gap de 36,9 pp
Zero-shot = 41,8% ← referência inferior
```

→ **Overfitting moderado.** O modelo aprendeu features do domínio (supera zero-shot por 5,2 pp) mas memoriza demais o treino. Dataset de 3.200 frames não é suficiente para from scratch sem regularização extra.

Cenário C — Fase 2 (melhor checkpoint)

```
Treino PCK@0.2 = 76,6%
Val PCK@0.2 = 61,5% ← gap de 15,1 pp
Zero-shot = 41,8% ← referência inferior
```

→ **Generalização boa.** Gap treino → val de 15 pp com ganho de **+19,7 pp** sobre o zero-shot. Os pesos COCO atuam como regularizador implícito.

Cenário C — Fase 3 (degradação)

A Fase 3 (descongelar até stage 1) **degradou a performance** de 61,5% → 58,4% PCK@0.2. Isso indica que descongelar as primeiras camadas do backbone com apenas 3.200 amostras causa overfitting nos estágios de baixo nível. **Para os Cenários B e D, considerar encerrar em Fase 2 se Δ PCK for negativo.**

7. Conclusões e Próximos Passos

O que foi validado no Épico 1

- ✓ Pipeline de fine-tuning funcional end-to-end (DSP3Dataset → MMPose → checkpoint → avaliação)
- ✓ Cenário A (from scratch) treina e avalia corretamente
- ✓ Cenário C (transfer learning) com progressive unfreezing funcional
- ✓ Docker com GPU na RTX 4090, reproduzível via `docker compose`

Implicações para o Épico 2

- Cenário C Fase 2 é o melhor resultado atual** (PCK@0.2 = 61,5%) — servir como referência principal para comparação com Cenários B e D
- Cenário D** (TL + augmentation) tem potencial de superar C, especialmente em wrist/elbow onde C ainda é fraco
- Fase 3 do progressive unfreezing** pode ser prejudicial — monitorar delta entre fases antes de executar
- Cenário B** (from scratch + augmentation) deve superar A em wrist/elbow mas provavelmente não alcançará C

Ordem de prioridade para Épico 2

Prioridade	Cenário	Justificativa
Alta	D (TL + aug)	Potencialmente o melhor; complementa C
Alta	B (scratch + aug)	Isola efeito do aug; completa a matriz
—	A e C	✓ Já executados

Gerado automaticamente a partir dos arquivos em `results/tables/`. Treinamento realizado na madrugada de 03–04 de junho de 2026 na GPU RTX 4090 (ubuntu-lab150-c4).